Построение алгоритма градиентного бустинга

- 1. Загрузите выборку golf_players.csv. В данной задаче целевая переменная Golf Players количество игроков в гольф, которое зависит от погодных условий: облачности, температуры воздуха, влажности и силы ветра в рассматриваемый день. При необходимости преобразуйте исходные признаки в числовые векторы. Постройте алгоритм градиентного бустинга, где в качестве базового алгоритма $b_t(x)$ выступает дерево решений глубины 2 (для построения решающего дерева использовать DecisionTreeRegressor из sklearn).
- 2. Количество алгоритмов в композиции -3 (кроме a_0). Для построения используйте среднеквадратичную функцию потерь:

$$\mathcal{L}(y, a(x)) = \frac{1}{2}(y - a(x))^{2}.$$

- 3. На каждом шаге алгоритма выбирайте α_t путем решения задачи одномерной оптимизации (функция minimize в scipy).
- 4. Как менялось качество предсказаний на каждом шаге алгоритма? Выведите график зависимости значения среднеквадратичной ошибки от номера итерации.

Алгоритм градиентного бустинга

Инициализировать первый алгоритм:

$$a_0(x) = \arg\min_{\gamma} \sum_{i=1}^{l} \mathcal{L}(y_i, \gamma).$$

В случае среднеквадратичной функции потерь оптимальный $a_0(x)$ – среднее значение y.

Для всех t = 1, ..., T:

1. Вычислить псевдоостатки в каждой точке обучающей выборки:

$$r_{i,t} = -\left[\frac{\partial \mathcal{L}(y_i, a(x_i))}{\partial a(x_i)}\right]_{a=a_{t-1}}$$

- 2. Обучить алгоритм $b_t(x)$ на $(x_i, r_{i,t})_{i=1,...,l}$
- 3. Найти α_t путем минимизации:

$$\alpha_t = \arg\min_{\alpha} \sum_{i=1}^{l} \mathcal{L}(y_i, a_{t-1}(x) + \alpha b_t(x)).$$

4. Добавить алгоритм в композицию:

$$a_t(x) = a_{t-1}(x) + \alpha_t b_t(x).$$

Вернуть композицию $a_t(x)$.